



# Rețele neurale LSTM pentru serii de timp

- PREDICȚIA PREȚULUI ACȚIUNILOR -

Burlacu Mircea-Florian  
Grupa 463  
CTI




# Cuprins


1. Problema abordată
2. Use cases
3. Tehnic
4. Tehnologii folosite
5. Rezultate
6. Concluzii
7. Bibliografie

# Problema abordată

- Categoria rețelelor neurale recurente (RNN) are o caracteristică specială, și anume faptul că dispun de *persistență*.
- Persistența este o problemă în cazurile în care o rețea neurală are nevoie de context pentru o predicție (*vanishing gradient problem*).
- O rețea neurală recurentă este structurată ca o mulțime de copii ale aceleiași rețele, fiecare dintre aceste copii transmițând un mesaj succesorului.



- Rețelele neurale LSTM (Long Short-Term Memory) vin ca o rezolvare la problema rețelelor RNN tradiționale, mai exact acestea pot învăța dependențe long-term, și deci pot face conexiuni între date care nu sunt apropiate.  
Spre deosebire de o rețea RNN standard, care are un singur layer, o rețea LSTM are 4 layer-uri, care interacționează.





# Use cases

Rețelele neurale LSTM pot fi folosite, printre altele, pentru:

- Probleme de clasificare
- Probleme de procesare
- Predicție bazată pe serii de timp

# Tehnic

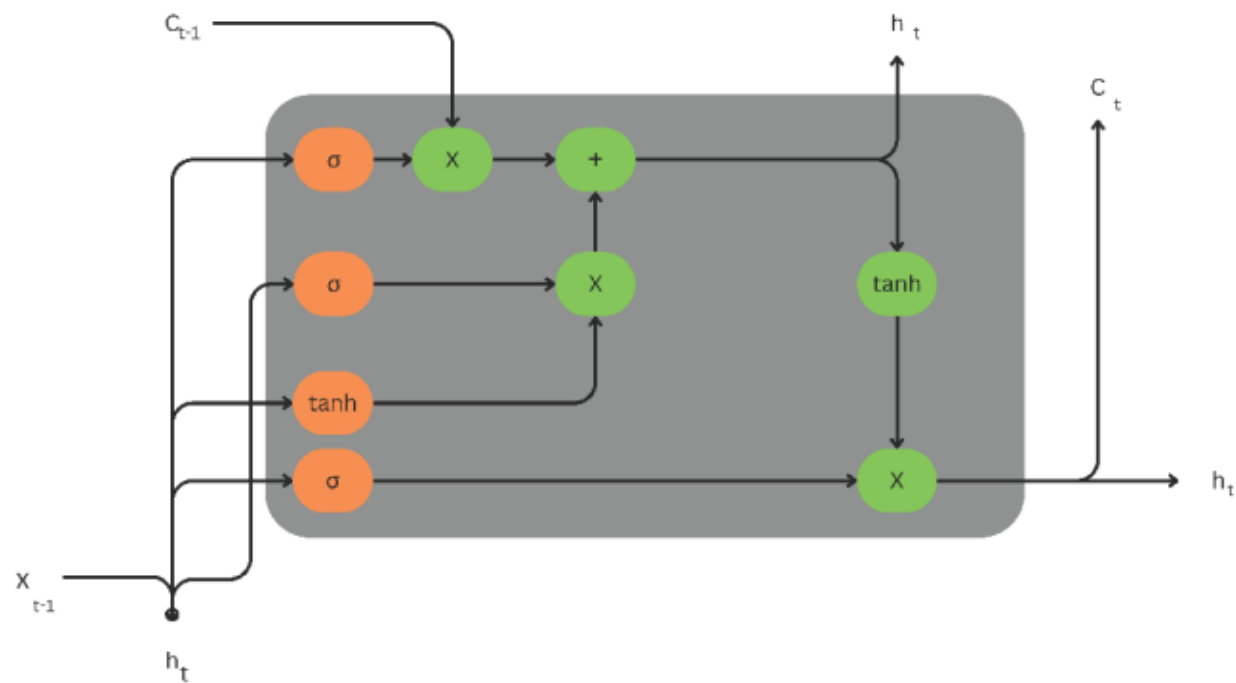


Diagrama unui layer ascuns dintr-un LSTM

- 
- Forget gate:

$$f_t = \sigma_g(W_f x_t + U_f h_{t-1} + b_f)$$

- Input gate:

$$i_t = \sigma_g(W_i x_t + U_i h_{t-1} + b_i)$$

- Cell state:

$$\tilde{c}_t = \sigma_c(W_c x_t + U_c h_{t-1} + b_c)$$

$$c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t$$

- Output gate:

$$o_t = \sigma_g(W_o x_t + U_o h_{t-1} + b_o)$$

$$h_t = o_t \odot \sigma_h(c_t)$$

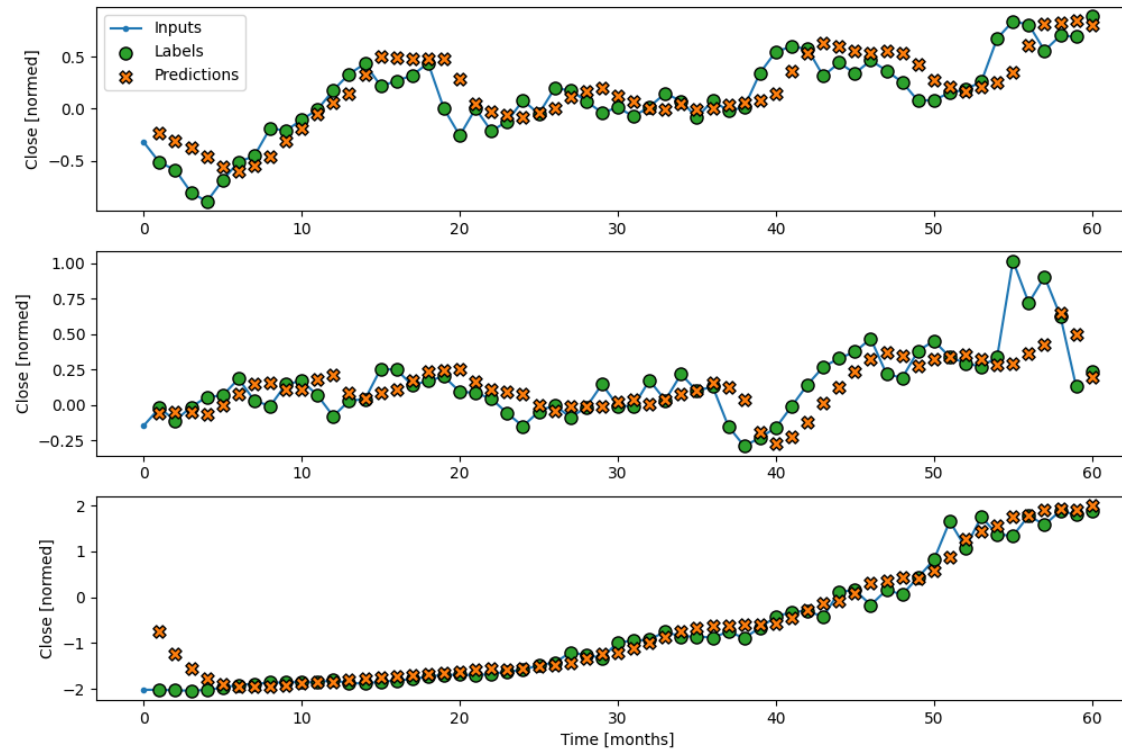
# Tehnologii folosite

- Tensorflow Keras [LSTM](#)
- Pandas (procesare de date)
- Altele:
  - MSFT – Closing price, lunar, ultimii 30 de ani ([Yahoo finance](#))

```
tf.keras.layers.LSTM(  
    units,  
    activation='tanh',  
    recurrent_activation='sigmoid',  
    use_bias=True,  
    kernel_initializer='glorot_uniform',  
    recurrent_initializer='orthogonal',  
    bias_initializer='zeros',  
    unit_forget_bias=True,  
    kernel_regularizer=None,  
    recurrent_regularizer=None,  
    bias_regularizer=None,  
    activity_regularizer=None,  
    kernel_constraint=None,  
    recurrent_constraint=None,  
    bias_constraint=None,  
    dropout=0.0,  
    recurrent_dropout=0.0,  
    return_sequences=False,  
    return_state=False,  
    go_backwards=False,  
    stateful=False,  
    time_major=False,  
    unroll=False,  
    **kwargs  
)
```



# Rezultate



# Concluzii

- Rețelele neurale LSTM reprezintă instrumente mai performante decât rețelele RNN standard, și au început să fie folosite în cât mai multe aplicații ()
- Cu toate acestea, rețelele LSTM nu sunt "the final frontier" pentru RNN. ("[Show, Attend and Tell: Neural Image Caption Generation with Visual Attention](#)", Xu K. et al. , 2015)



# Bibliografie

- ["LONG SHORT-TERM MEMORY"](#), Hochreiter S., Schmidhuber J. , 1997
- ["Learning to Forget: Continual Prediction with LSTM"](#), Gers F.A.; Schmidhuber J.; Cummins F. , 2000
- ["Sequence labelling in structured domains with hierarchical recurrent neural networks"](#), Fernández S.; Graves A.; Schmidhuber J. - 2007
- [Understanding LSTMs](#) - 2015
- [Long short-term memory](#)
- [Vanishing gradient problem](#)